

SK 네트워크 Family AI 27기 : ____팀

데이터 전처리 결과서

산출물 단계	데이터 전처리
제출 일자	2026. 4. 18.
깃허브 경로	
작성 팀원	000

데이터 전처리 프로세스 (Data Preprocessing)

1. 전처리 개요

1-1. 코어

- 전처리 목적 : 멀티 에이전트·RAG 파이프라인에 투입 가능한 학습·검색용 고품질 데이터 생산
- 전처리 범위 : 정형 DB 데이터 및 비정형 문서·로그(원천 → 정제 → 청킹·임베딩)
- 사용 도구 : pandas, numpy, re, kiwipiepy, nltk, scikit-learn, LangChain, sentence-transformers

1-2. 이동 에이전트

- 전처리 목적 : 이동·동선 판정기(코드)가 읽는 참조 데이터(지하철 시간표·역 순서·좌표·환승도보·혼잡도·버스·공항 리무진·공휴일)를 소스 간 정합성이 검증된 형태로 생산한다. 판정 경로에 LLM·RAG가 없으므로 임베딩·청킹 단계는 두지 않는다.
- 전처리 범위 : 공공 정형 데이터(API 응답·CSV·XLSX) 원천 → 정규화(시각·행선지·역명) → 소스 간 대조(C1~C6) → SQLite 적재(13표, PostgreSQL 전환 예정). 비정형 문서·개인정보 없음.
- 사용 도구 : Python 3.11, requests, python-dotenv, csv·json, sqlite3, openpyxl; 검증 스크립트 consistency_check.py · check_line_station_order.py · verify_time.py · selfcheck_mobility.py · load_mobility_db.py

1-3. 액티비티 에이전트

- 전처리 목적 :
- 전처리 범위 :
- 사용 도구 :

1-4. 요식업 에이전트

- 전처리 목적 :
- 전처리 범위 :
- 사용 도구 :

2. 원천 데이터 분석

2.1 데이터 출처 및 현황

- 코어

이슈 유형	대상 필드	판정 기준	처리 방식	처리량 / 비교
결측치	content	NULL / 빈 문자열	행 제거	79건
결측치	category	NULL	'기타' 대체	416건
중복치	doc_id	동일 ID	drop_duplicates	124건
중복치	content	SHA1 / MinHash Jaccard ≥ 0.92	대표본 유지	525건
이상치	content_length	< 2자 또는 상위 0.1%	행 제거 또는 분할	60건
형식 불일치	timestamp	ISO-8601 외 포맷	파싱 후 재저장	1,204건

- 이동 에이전트

이슈 유형	대상 필드	판정 기준	처리 방식	처리량 / 비교
결측치	dep_time (‘000000’)	출발 없음 = 시·종착역	NULL 유지 · 판정 제외	18,411행 (수집 463,326 → 유효 444,915)
결측치	dest_nm	종착 행 복원 실패	NULL 유지 → 판정 '근거없음'	18,411행 (수집 463,326 → 유효 444,915)
중복치	timetable (source,역,요일, 방향,dep,arr,dest, train_no)	보충 수집이 만든 동일 열차	양방향 중복 제거 (TAGO 84행 우선 제거)	접속역 통째 수집 중복 · 종착 행 휴일 2중
중복치	종착 행 (TRAIN_NO)	같은 종착역 2행 = 모호함 아님	종착 '역' 수로 판정 (len(names)==1)	+2,262행 · 487열차 복원
이상치	dest_nm == 역명	같은 종착역 2행 = 모호함 아님	terminates_here() 필터 + 시발열차 판별(≥ 0.5)	3,651행 · 막차 26조합 정정
이상치	자정 넘김 시각	00:05 가 그날 최소값	분 단위 정수, 24h+ 유지	C4 불일치 757→7 · 652→40

형식 불일치	SUBWAYSNAME	행선지가 아니라 시발역	orig_nm 로 분리, dest_nm 은 TRAIN_NO 복원	41,510행(8.9%) · 101조합 역전
형식 불일치	역명·노선명	'역' 접미·괄호·1자리 노선	접미 제거 · 0 패딩(05호선)	미정규화 시 52,844행 조인 실패
구조 예외	역 순서 · 지선	'역' 접미·괄호·1자리 노선	정본 FR_CODE · 등급 하향+경고 · 간선 교체	777간선 통과 · MOB_W_SINJEONG _SAT

- 액티비티 에이전트

이슈 유형	대상 필드	판정 기준	처리 방식	처리량 / 비교

- 요식업 에이전트

이슈 유형	대상 필드	판정 기준	처리 방식	처리량 / 비교

2.2 품질 이슈 진단

- 코어

처리 단계	입력	출력	목적
형식 정합성	원천 다중 포맷	UTF-8 / ISO-8601	인코딩·스키마 통일
중복 제거	정합 데이터	고유 문서 집합	학습 편향 방지
결측·이상치 처리	고유 문서 집합	정제 코퍼스	품질 확보
정규화 / 마스킹	정제 코퍼스	표준화·마스킹 텍스트	모델 입력 일관·개인정보 보호
분할·청킹	표준화 텍스트	Train/Val/Test + 청크	학습·RAG 동시 구성

- 이동 에이전트

처리 단계	입력	출력	목적
수집	공공 API 6종 · 파일 3종	raw/mobility/*.json(l)·csv· xlsx	원천 보존 · 수집일 기록
정규화	원천 다중 포맷	processed/*.jsonl (분 단위 시각·정규 역명·복원 행선지)	소스가 서로 다른 말을 하는 자리를 맞춤
중복 제거	정규화 시간표	고유 열차 집합	보충 수집 중복 제거 · 중착 행 중복 판정
결측·이상치 처리	고유 열차 집합	판정 유효 444,915행	출발 없음 제외 · 중착 열차 필터 · 가짜 막차 제거
소스 간 대조	processed 전체	C1~C6 · 역 순서 777간선 통과	한 소스만 보면 정상인 결함 검출
적재·검증	processed	SQLite 13표 (참조 10·산출 2·메타 1)	점검 11가지 · 회귀 85 · 자기점검 8,648

- 액티비티 에이전트

처리 단계	입력	출력	목적
-------	----	----	----


● 요식업 에이전트

처리 단계	입력	출력	목적

2.3 전처리 파이프라인 흐름도

● 코어

● 이동 에이전트



- 요식업 에이전트

3. 정제 · 가공 · 분할 절차 및 후속 활용

- 코어

3.1 학습 / 검증 / 테스트 분할

- 분할 기준 : 층화 추출 (category 기준, random_state=42)

필드	타입	결측 처리	중복 처리	이상치 처리	비고
doc_id	STRING	필수	drop_duplicates	-	PK
content	TEXT	결측 행 제거	해시 기반	길이 필터	임베딩 대상
category	CATEGORY	'기타' 대체	-	빈도 <5 병합	분류 라벨
intent	CATEGORY	규칙 보강	-	-	의도 분석
timestamp	DATETIME	수집일 대체	-	미래 날짜 제거	ISO-8601

3.2 후속 단계 활용 적합성 및 재현성 관리

구분	항목	기준 / 결과	설명 및 관리 방안
분할	학습	80% (8,000건)	층화 추출 (random_state=42)
분할	검증	10% (1,000건)	조기 종료 판단
분할	테스트	10% (1,000건)	최종 평가용, 학습과 격리
품질	결측 제거	79건	content 기준
품질	중복 제거	649건	해시 + MinHash
품질	이상치 제거	76건	길이·시간 필터
품질	민감정보 마스킹	2,318건 치환	이메일·전화·사번 정규식
후속 활용	ML/DL 학습	CSV · Parquet (label)	XGBoost·BERT 학습 입력
후속 활용	RAG (벡터DB)	JSONL + 청크 메타	512 토큰 · 50 오버랩
후속 활용	GraphDB	트리플 CSV	엔터티 관계 추출

후속 활용 / 재현성	에이전트 호출·기록	JSON 스키마 + seed/해시 로그	MCP 도구 인자 직렬화, README 명시
----------------	---------------	--------------------------	--------------------------

● 이동 에이전트

3.1 학습 / 검증 / 테스트 분할

- 분할 기준 : 학습용 Train/Val/Test 분할 없음(판정은 코드). 검증 측은 회귀 85건(사람이 기대값을 박은 케이스 5파일, --check-expect) · 자기점검 탐침 8,648건(구간 23종 × 왕복 × 요일 4 × 47시각, 정답 없이 불변식 9종) · ML 대조 실험은 구간 단위 GroupKFold 5폴드 × 시드 5회

필드	타입	결측 처리	중복 처리	이상치 처리	비고
line · station_nm	STRING	필수 (없으면 행 제외)	정규화 후 키 조인	시간표에 없는 역 → 근거없음	복합키 · 0 패딩
dep_min	INTEGER(분)	NULL 유지 (출발 없음)	-	24h+ 허용 · 0/24 대체 금지	막차 판정 축
dest_nm / orig_nm	STRING	NULL 유지 → 근거없음	종착 '역' 수로 판정	dest==역명 행 필터	행선지·시발역 분리
train_no	STRING	필수	양방향 중복 제거 키	-	열차 단위 복원 키
congestion	FLOAT	NULL 유지 (열차 없음)	-	0% 로 대체 금지	정보 레이어
term_min	INTEGER	NULL 유지 (배차 개념 없음)	-	0 대체 금지	버스 대기

3.2 후속 단계 활용 적합성 및 재현성 관리

구분	항목	기준 / 결과	설명 및 관리 방안
검증	회귀	85건 전부 통과 (어긋남 0)	real 32 · issue 9 · alt 5 · bus 11 · synthetic 28(축소 시간표)
검증	자기점검	탐침 8,648건 · 치명 0 · 판단불가율 4.35%	정답 없이 불변식 9종 · 탐지기 자체 점검 10/10

검증	ML 대조 실험	GroupKFold 5폴드 × 시드 5	구간 단위 분할 · 회귀 85건 외부 시험
품질	결측 제거	18,411행 (출발 없음)	NULL 유지, 판정에서 제외
품질	중복 제거	TAGO 84행 · 종착 중복 판정 개선 +2,262행	행 수가 아니라 서로 다른 값의 수로 판정
품질	이상치 제거	종착 열차 3,651행 · 가짜 막차 2,527행	terminates_here() · '000000' 비시각 처리
품질	민감정보 마스킹	해당 없음 (0건)	전부 공공데이터 · 식별자 미수집 · 경로 API 응답 미저장(스키마 CHECK)
후속 활용	ML/DL 학습	탐침 8,648건 + 특징 27 (numpy)	대조 실험 전용 · 판정 경로 미투입 (학습 결과서)
후속 활용	RAG (벡터DB)	두지 않음	정확한 값 조회이지 의미 검색 아님 · 4W 에 경로 B 비교
후속 활용	GraphDB	역 순서 간선 777 (line, from, to, travel_min)	SQL 표로 보관, 별도 GraphDB 없음
후속 활용 / 재현성	판정기·에이전 트 호출	SQLite 13표 · timetable_built_at · rules_version	재현 명령 10종(REPORT.md) · --step 명시 · 실행 시간은 인용 안 함

- 액티비티 에이전트

3.1 학습 / 검증 / 테스트 분할

- 분할 기준 : 층화 추출 (category 기준, random_state=42)

필드	타입	결측 처리	중복 처리	이상치 처리	비고

3.2 후속 단계 활용 적합성 및 재현성 관리

구분	항목	기준 / 결과	설명 및 관리 방안

- 요식업 에이전트

3.1 학습 / 검증 / 테스트 분할

- 분할 기준 : 층화 추출 (category 기준, random_state=42)

필드	타입	결측 처리	중복 처리	이상치 처리	비고

3.2 후속 단계 활용 적합성 및 재현성 관리

구분	항목	기준 / 결과	설명 및 관리 방안

4. 변경 이력 및 적용 전략

변경일	변경자	변경내용	영향 받는 항목	비고
2026.04.11	전체	초안 작성 : 전처리 파이프라인 정의	전체	v1.0
2026.04.13	000	품질 이슈 기준 및 RAG 청킹 반영	t3, t4, t6	v1.1